

MyoTrackML: Análisis de señales EMG de base de datos para la detección de patrones de fatiga muscular en miembro inferior

1st Hans Ortiz Valverde

*Facultad de Ciencias e Ingeniería
Pontificia Universidad Católica
del Perú
Lima, Perú
sample*

2nd Martin Elias Pino Aguilar

*Facultad de Ciencias e Ingeniería
Pontificia Universidad Católica
del Perú
Lima, Perú
sample*

3rd Alejandro Janampa Sopla

*Facultad de Ciencias e Ingeniería
Pontificia Universidad Católica
del Perú
Lima, Perú
sample*

4th Yamil Alexis Yapuchura Mamani

*Facultad de Ciencias e Ingeniería
Pontificia Universidad Católica del Perú
Lima, Perú
sample*

5th Janella Kiomi Aponte Diaz

*Facultad de Ciencias e Ingeniería
Pontificia Universidad Católica del Perú
Lima, Perú
jkaponte@pucp.edu.pe*

Resumen—This document is a model and instructions for L^AT_EX. This and the IEEEtran.cls file define the components of your paper [title, text, heads, etc.]. *CRITICAL: Do Not Use Symbols, Special Characters, Footnotes, or Math in Paper Title or Abstract.

Index Terms—component, formatting, style, styling, insert

I. INTRODUCCIÓN

La fatiga muscular, definida como la incapacidad para mantener un nivel específico de fuerza o continuar una actividad física a intensidad establecida [1]. Reduce la capacidad del tejido muscular para absorber energía y también altera sus propiedades contráctiles, incrementando el riesgo de lesiones espontáneas durante actividades deportivas o laborales. [2]. En extremidades inferiores, la fatiga del cuádriceps/isquiotibiales reduce la estabilidad de la rodilla, afectando al ligamento cruzado anterior [3]. Además, altera la discriminación de velocidades de movimiento en brazos, generando coactivación muscular excesiva y movimientos ineficientes [4].

Si no se detecta o gestiona adecuadamente, la fatiga muscular puede desencadenarse en trastornos musculoesqueléticos (TME) con alto impacto en la salud pública [5]. Según la Organización Mundial de la Salud (OMS), aproximadamente 1.710 millones de personas a nivel global padecen TME, siendo el dolor lumbar la manifestación más prevalente afectando a 568 millones y es la principal causa de discapacidad en 160 países [6]. En Europa, los TME constituyen la principal causa de ausentismo laboral; en España, representan el 81.6 % de las enfermedades profesionales reportadas; y en América Latina y el Caribe, se estima que 52 millones de personas sufren estos trastornos, con mayor carga en mujeres y mayores de 50 años [7] [8] [9]. Mientras tanto, a nivel de Perú, el 73 % de los trabajadores experimentan dolor musculoesquelético,

sobretudo en la región lumbar, hombros y muñecas [10]. Ante

esta elevada prevalencia y sus consecuencias socioeconómicas, resulta esencial implementar técnicas de detección temprana no invasivas. Métodos como la electromiografía, ultrasonido dinámico y análisis de presión plantar emergen como herramientas prometedoras para monitorear la fatiga y prevenir su progresión [11]. Entre estas, se elige la técnica de EMG de superficie para la elaboración de esta investigación debido a ser de alta resolución temporal, bajo costo y no invasiva [12].

II. JUSTIFICACIÓN

La fatiga muscular no detectada o mal diagnosticada en las extremidades superiores e inferiores constituye un factor de riesgo crítico para el desarrollo de lesiones músculo-esqueléticas, afectando directamente la salud de los individuos, disminuyendo el rendimiento en actividades deportivas y reduciendo la productividad en contextos laborales [2] [3] [4] [7] [8] [9].

Tal que se propone una aplicación de escritorio desarrollada en Python, capaz de analizar señales EMG (electromiografía) mediante filtrado digital y extracción de características cuantitativas como RMS, MAV, ZC, SSC y WL que permiten identificar patrones asociados a la fatiga muscular. El sistema presenta una interfaz gráfica intuitiva mediante PyQt5 y permite exportar los resultados a un informe en PDF, facilitando su uso en entornos clínicos, deportivos o laborales. La aplicación contribuye al desarrollo de herramientas accesibles para el monitoreo preventivo de la fatiga, con potencial impacto en la reducción de TME y mejora del rendimiento físico en diversas poblaciones.

III. METODOLOGÍA

A. Materiales

Se emplearon registros electromiográficos (EMG) de acceso público provenientes de la base de datos sEMG/1.0.1 de PhysioNet [13], los cuales incluyen señales multicanal de músculos de miembros inferiores en formato fisiológico estándar (.hea/.dat). El entorno de desarrollo fue Python 3.12, utilizando bibliotecas especializadas de procesamiento de señal: WFDB para la lectura de señales fisiológicas, SciPy para filtrado digital, NumPy para cálculos numéricos y PyWavelets (pywt) para análisis espectral mediante Transformada Wavelet. Para la visualización de datos se empleó Matplotlib, y en el módulo de aprendizaje automático se usó scikit-learn (implementación de Random Forest) con apoyo de pandas para manejo de datos. La interfaz gráfica de usuario (GUI) fue desarrollada con PyQt5, y el software resultante se empaquetó como una aplicación de escritorio autónoma compatible con sistemas operativos Windows.

B. Protocolo

Para llevar a cabo este estudio, seguimos el protocolo descrito a continuación:

1) *Adquisición de datos:* Se cargan las señales EMG crudas a partir de archivos fisiológicos (.hea junto con .dat) obtenidos de la base de datos pública PhysioNet, la cual proporciona registros multicanal por sujeto. Estas señales provienen de los músculos del miembro inferior y constituyen la base de datos de entrada.

2) *Pre-procesamiento:* La señal bruta de cada canal es sometida a filtrado digital para atenuar el ruido y restringir el análisis al rango de frecuencias de interés en EMG. En particular, se aplica un filtro Butterworth pasabanda de 4º orden entre 20 Hz y 450 Hz, tras lo cual la señal filtrada es rectificada (valor absoluto) para obtener su envolvente electromiográfica, lo cual permite limpiar la señal y prepararla para la extracción de características posteriores.

3) *Segmentación:* La señal continua rectificada se divide en segmentos temporales utilizando una ventana móvil deslizante. Por lo que se emplearon ventanas de 5 segundos de duración (con solapamiento entre ventanas sucesivas) para capturar la evolución temporal de la fatiga. Cada ventana representa un intervalo de señal sobre el cual se calcularán las métricas descriptivas, logrando así un análisis cuadro a cuadro de la progresión de la fatiga en el tiempo.

4) *Extracción de características:* A cada ventana se le calcula un conjunto de métricas cuantitativas que sirven como indicadores de fatiga muscular. En el dominio temporal se obtiene el RMS (Root Mean Square), que refleja la magnitud o energía de la señal, y el conteo de ZC (Zero Crossings), que cuantifica el número de veces que la señal cruza por cero dentro de la ventana que se relaciona con la actividad muscular. Adicionalmente, se extraen características frecuenciales como la MNF (Mean Frequency) y MDF (Median Frequency), que resumen la distribución espectral de la señal en cada segmento. Para el cálculo de MNF y MDF se aplica la Transformada

Continua de Wavelet (CWT) a cada ventana, obteniendo el espectro de potencia instantáneo a partir del cual se estima la frecuencia media y la frecuencia mediana respectivamente. Las cuatro características RMS, ZC, MNF y MDF proporcionan información complementaria sobre los cambios en amplitud y contenido frecuencial de la EMG asociados a la fatiga.

4) *Clasificación de fatiga:* En esta etapa se evalúan las características extraídas de cada ventana para poder determinar la presencia y el grado de fatiga muscular, de modo que se implementaron dos enfoques de clasificación paralelos. El primero es un método clásico basado en umbrales provenientes de la literatura biomédica, el cual detecta fatiga cuando se observan variaciones significativas en las métricas respecto a sus valores iniciales como el incremento del RMS y disminución de MNF/MDF en comparación al comienzo de la contracción [13]. El segundo es un método automático de Machine Learning que emplea un modelo Random Forest pre-entrenado para identificar patrones de fatiga de forma más generalizada [13]. El modelo fue entrenado con un amplio conjunto de datos (más de 15,000 ventanas etiquetadas, provenientes de 31 sujetos diferentes) para clasificar cada ventana en distintos niveles de fatiga de manera automatizada. Ambos enfoques entregan como resultado una tabla donde se muestra el análisis de la fatiga en cada ventana con sus respectivos datos de interés.

5) *Visualización de resultados y reportes:* Los resultados del análisis se presentan de forma gráfica e interpretativa a través de la interfaz desarrollada. Se identifican y visualizan únicamente aquellas ventanas en las que se detectaron patrones de fatiga, descartando tramos sin indicios relevantes. Cada ventana con fatiga se representa mediante un código de color según la severidad del hallazgo (leve, moderado o grave), y se acompaña de una recomendación específica basada en el nivel de fatiga detectado. Adicionalmente, se genera una tabla interactiva o resumen gráfico por músculo y ventana, que permite al usuario revisar de forma organizada las predicciones del sistema. La tabla incluye las siguientes columnas: Músculo afectado, nivel de fatiga detectado, intervalo temporal en segundos correspondiente a la ventana analizada y su respectiva recomendación sobre cómo actuar frente al nivel de fatiga detectado. Finalmente, se ofrece la opción de exportar un informe en formato PDF, el cual consolida los resultados gráficos y los datos del paciente, así como un archivo CSV con los valores cuantitativos extraídos (RMS, ZC, MNF, MDF) y las predicciones de fatiga.

IV. RESULTADOS Y DISCUSIÓN

Se observaron tendencias consistentes en los músculos donde se apreciaron la aparición de la fatiga muscular. En particular, las características espectrales MNF y MDF mostraron una tendencia descendente a lo largo de la prueba de marcha, mientras que la amplitud RMS tendió a incrementarse ligeramente hacia el final del periodo analizado. Tal que es congruente con la literatura clásica de fatiga muscular, la cual asocia el progreso de la fatiga con una caída del contenido de alta frecuencia en la EMG acompañada de un aumento

en la amplitud del esfuerzo debido a la activación de unidades motoras adicionales [14] [15]. La métrica ZC presentó variaciones dependientes del músculo y del sujeto, pero en general también reflejó cambios en la frecuencia efectiva de activación muscular, complementando la información brindada por MNF/MDF.

Empleando el método clásico de umbrales, se pudo determinar el instante aproximado en que cada músculo comenzó a mostrar signos de fatiga. Un patrón observado es que los músculos más grandes del muslo como el vasto lateral o el recto femoral muestran cambios más graduales en sus parámetros, permaneciendo en fatiga leve o incipiente en el mismo intervalo temporal; dado que cada grupo muscular soporta cargas distintas durante la locomoción estas diferencias son esperables. En las pruebas realizadas, la clasificación automática de cada ventana arrojó niveles de fatiga que en la mayoría de los casos coincidieron con los determinados por el método clásico para las mismas ventanas. Además, el modelo logró detectar algunas señales sutiles de fatiga incipiente en etapas tempranas de la marcha: en ciertos sujetos, el Random Forest clasificó ventanas como "fatiga leve" ligeramente antes de que los umbrales tradicionales se sobrepasaran. El enfoque de aprendizaje automático ha demostrado ser más sensible a combinaciones de cambios mínimos en las múltiples características que, de forma aislada, podrían no activar un umbral predefinido. En otras palabras, la inteligencia artificial integró la información de forma óptima, anticipando tendencias que el método clásico podría pasar por alto si los cambios están cerca del límite de detección. Gracias al amplio conjunto de entrenamiento, el clasificador aprendió a reconocer patrones de fatiga a pesar de las diferencias fisiológicas individuales.

La visualización mediante el entorno virtual con codificación de colores implementada resultó ser una herramienta, puesto que resume de forma intuitiva el estado de fatiga de cada músculo a lo largo del tiempo, facilitando la interpretación: por ejemplo, se podía identificar de un vistazo qué músculos se encontraban con fatiga leve (amarillo), moderada (naranja) o severa (rojo) en determinado momento. Esta información se puede exportar vía CSV/PDF donde queda registrado el valor de cada característica por ventana junto con la etiqueta de fatiga asignada. En general, los resultados demuestran que ambos enfoques de detección capturan adecuadamente los patrones de fatiga muscular en las señales EMG analizadas. El método basado en umbrales ofrece un criterio transparente y directamente ligado a parámetros fisiológicos, mientras que el método basado en aprendizaje automático aporta consistencia y sensibilidad mejoradas.

En síntesis, la combinación de ambos en una misma plataforma proporciona al especialista una herramienta integral: primero, para visualizar y cuantificar objetivamente la evolución de la fatiga, y segundo, para disponer de un diagnóstico automatizado complementario que puede apoyar la toma de decisiones.

V. CONCLUSIÓN

Se desarrolló un sistema informático capaz de analizar señales EMG de forma automatizada para detectar patrones de fatiga muscular en miembros inferiores, integrando técnicas clásicas de procesamiento de señales con algoritmos de aprendizaje automático. La plataforma resultante, implementada en Python con una interfaz gráfica amigable, permite procesar múltiples canales EMG simultáneamente, extraer características clave y emitir un diagnóstico de fatiga de manera objetiva y reproducible, superando las limitaciones del análisis manual tradicional. El enfoque propuesto demostró que la combinación de métricas temporales (RMS, ZC) y frecuenciales (MNF, MDF) con métodos duales de detección (umbrales versus modelo Random Forest) proporciona una evaluación robusta y confiable del estado de fatiga muscular en señales reales de sujetos caminando.

Los resultados obtenidos validan la utilidad de la herramienta tanto para investigar la fisiología de la fatiga durante esfuerzos prolongados, como para apoyar aplicaciones en rehabilitación y entrenamiento, donde es crucial prevenir la sobrecarga muscular.

En conclusión, MyoTrackML cumple con el objetivo de asistir a profesionales y investigadores en la identificación temprana de fatiga muscular de miembros inferiores de forma no invasiva. Como trabajo futuro, se propone extender la funcionalidad de la plataforma en varias direcciones. En primer lugar, podría aplicarse a la detección de fatiga en miembros superiores u otros grupos musculares, adaptando la interfaz y el modelo de acuerdo con las características de nuevas bases de datos EMG. Otra línea de desarrollo a considerar es la habilitación del procesamiento en tiempo real de las señales EMG, de modo que el sistema pueda emplearse con dispositivos de adquisición portátiles y brindar retroalimentación inmediata al usuario.

REFERENCIAS

- [1] J. A. Martínez Mesa, «FATIGA. TIPOS Y CAUSAS», Rev.Cub.Med.Dep.amp;Cult.Fis., vol. 8, n.º 3, nov. 2020.
- [2] F. Jiménez Díaz, "Lesiones musculares en el deporte (Muscular injuries in sport)," RICYDE. Revista Internacional de Ciencias del Deporte*, vol. 2, no. 3, pp. 55–67, 2011. [En línea]. Disponible en: <https://www.cafyd.com/REVISTA/ojs/index.php/ricyde/article/view/70>
- [3] A. A. Sayáns Torres y M. Soto González, "Cocontracción y coactivación muscular en lesiones del ligamento cruzado anterior. Una revisión bibliográfica", Rehabilitación, vol. 52, n.º 3, pp. 184–194, julio de 2018. Accedido el 22 de junio de 2025. [En línea]. Disponible: <https://doi.org/10.1016/j.rh.2018.03.002>
- [4] P. M. Sierra, C. F. Rodríguez, C. S. L. de Pablo, E. J. U. Jiménez, y R. R. López, "Estudio del coeficiente de coactivación muscular en flexo-extensión de codo en distintas condiciones de peso con el uso de EMG," Jornadas de Automática*, no. 45, 2024.
- [5] L. V. Balcazar-Peralta y J. L. Solano-Peláez, «Impacto de pausas activas en la disminución de trastornos músculo esqueléticos en personal oficinista», MQRInvestigar, vol. 9, n.º 2, p. e614, may 2025.
- [6] Trastornos musculoesqueléticos. (s.f.). World Health Organization (WHO). <https://www.who.int/es/news-room/fact-sheets/detail/musculoskeletal-conditions>
- [7] "Trastornos musculoesqueléticos — Safety and health at work EU-OSHA". European Agency for Safety and Health at Work - Information, statistics, legislation and risk assessment tools. Accedido el 22 de junio de 2025. [En línea]. Disponible: <https://osha.europa.eu/es/themes/musculoskeletal-disorders#:~:>

text=Los%20trastornos%20musculoesqueléticos%20(TME)%20son,
la%20persona%20afectada%20sigue%20trabajando.

- [8] "Sindicato Unión General de Trabajadoras y Trabajadores de España," UGT, comunicado sobre prevención de trastornos músculo-esqueléticos en el entorno laboral, consultado el 22 de junio de 2025.
- [9] C. Mendoza-Pinto et al., "Burden of Other Musculoskeletal Disorders in Latin America and the Caribbean", JCR: J. Clin. Rheumatol., octubre de 2023. Accedido el 22 de junio de 2025. [En línea]. Disponible: <https://doi.org/10.1097/rhu.0000000000002034>
- [10] O. Vega-Hinojosa, M. H. Cardiel y P. Ochoa-Miranda, "Prevalence of Musculoskeletal Manifestations and Related Disabilities in a Peruvian Urban Population Living at High Altitude. COPCORD Study. Stage I", Reumatología Clínica (English Ed.), vol. 14, n.º 5, pp. 278–284, septiembre de 2018. Accedido el 22 de junio de 2025. [En línea]. Disponible: <https://doi.org/10.1016/j.reumae.2017.01.013>
- [11] N. Li et al., "Non-invasive Techniques for Muscle Fatigue Monitoring: A Comprehensive Survey", ACM Comput. Surv., febrero de 2024. Accedido el 22 de junio de 2025. [En línea]. Disponible: <https://doi.org/10.1145/3648679>
- [12] J. R. Torres Castillo, *Clasificación de señales EMG empleando características tiempo-frecuencia para el diagnóstico de desórdenes neuromusculares*, Tesis de Maestría, Programa de Maestría y Doctorado en Ingeniería Eléctrica - Procesamiento Digital de Señales, Universidad Nacional Autónoma de México, Ciudad de México, México, 2018.
- [13] F. Di Nardo, C. Morbidoni, and S. Fioretti, "Surface electromyographic signals collected during long-lasting ground walking of young able-bodied subjects (version 1.0.1)," PhysioNet, 2024. [Online]. Available: <https://doi.org/10.13026/grdj-qx06>
- [14] F. Liao, X. Zhang, C. Cao, I. Y.-J. Hung, Y. Chen, and Y.-K. Jan, "Effects of muscle fatigue and recovery on complexity of surface electromyography of biceps brachii," Entropy, vol. 23, no. 8, p. 1036, 2021. [Online]. Disponible: <https://doi.org/10.3390/e23081036>
- [15] M. R. Al-Mulla, F. Sepulveda, and M. Colley, "A review of non-invasive techniques to detect and predict localised muscle fatigue," Sensors, vol. 11, no. 4, pp. 3545–3594, 2011. [Online]. Disponible: <https://doi.org/10.3390/s110403545>